



CARMA-Affect: 组合条件效用学习与风险受控回退

(a) 测试期推理



(b) 训练与独立校准



(c) 实验设计

1. 数据集与角色

- MELD | 快速 Pilot
- EmotionTalk | 组合效用主实验
- IEMOCAP | 深历史、状态转折与恢复

2. 强制基线

- Current-only
- Full-history / 对话上下文
- Recent-k / Time Decay
- Semantic RAG top-k
- point utility gate
- 置信度回退 / SelectiveNet
- MemCon-style controller
- CARMA 消融
- Oracle 集合选择 (仅分析上界)

3. 核心指标与诊断

- harm rate | excess loss | 尾部伤害
- harm / excess-risk / F1-coverage
- macro / weighted F1 | NLL | Brier | ECE
- 条件方差 | 符号反转率
- 使用 $\rightarrow$ 忽略 $\rightarrow$ 恢复轨迹
- cluster bootstrap CI | 最坏组伤害

合成实验仅作参考 sanity check,
不代表真实数据证据; 测试集在模型、
阈值与分析代码冻结后仅运行一次。

蓝色: 测试期可见 | 推理模块

红色: 仅训练/校准期 | 不参与测试推理

绿色: 决策/评估 | 输出与评估

→ 推理/数据流

----→ 监督/校准流

图解：如何阅读 CARMA-Affect 方法框架

核心问题：在测试期不访问当前或历史真实情感标签的前提下，判断候选历史在已选集合 S 中的条件边际效用，选择相对 current-only 伤害风险经过策略级校准的历史子集；当没有安全候选时，可靠地回退到 current-only。

(a) 测试期推理

- 输入包括当前多模态话语 x_t ，以及严格早于当前话语的同说话人历史 $H_{<t}$ 。共享编码器提取当前/历史表征和模态可靠度。
- 效用预测器不是独立判断一条历史是否有效，而是估计候选 h_i 在已选集合 S 条件下的边际效用分布与伤害概率。
- 选择器在历史条数或 token 预算 K 内逐步加入安全边际最高的候选；只有下置信界 $LCB > 0$ 时才加入。
- 如果不存在安全候选，则令 $S^* = \text{空集}$ 并使用 $f_0(x_t)$ ；否则使用 $f(x_t, S^*)$ 输出当前情感预测。测试期禁止 gold emotion、未来信息和在线阈值更新。

(b) 训练与独立校准

- 训练集内部按 dialogue、episode 或 session 做嵌套 cross-fitting，避免由同一聚类单元造成折外效用泄漏。
- 每个查询采样 4-8 个 (S, h_i) ，其中 h_i 不属于 S ；分别产生折外预测 f_0 、 f_S 与 f_{S+h_i} 。
- 边际效用标签定义为加入 h_i 前后的预测损失差： $M = \text{loss}(f_S, y) - \text{loss}(f_{S+h_i}, y)$ 。 $M > 0$ 表示改善， $M < 0$ 表示负迁移。
- 独立 calibration split 冻结候选策略阈值，按聚类单位检验相对 current-only 的 excess risk，再选取满足约束的最激进策略。图中没有假设联合损失。

(c) 实验设计

- 数据集分工：MELD 用于快速 Pilot；EmotionTalk 承担组合效用主实验；IEMOCAP 用于深历史、状态转折和恢复验证。
- 基线覆盖 current-only、full-history、Recent-k、Time Decay、Semantic RAG、point utility gate、SelectiveNet、MemCon、CARMA 消融及 Oracle 上界。
- 结果不能只看平均 F1，还应同时报告 harm rate、excess loss、尾部伤害、风险-覆盖率曲线、NLL/Brier/ECE、符号反转率和恢复轨迹。
- 置信区间按 dialogue/episode/session 聚类 bootstrap，并报告最坏组伤害。合成实验只用于算法 sanity check，不能视为真实数据证据。

边界说明 风险约束针对独立校准后的完整选择策略，并依赖独立/交换性或聚类交换性假设；不能解释为对每个测试样本或任意现实时间漂移提供无条件安全保证。

开场

这张图概括了 CARMA-Affect 的完整研究框架。它要解决的不是简单地判断某一条历史是否有用，而是判断：在已经选择了一组历史 S 的条件下，再加入候选历史 h_i ，会改善还是损害当前情感预测；如果潜在伤害不可接受，模型应回退到只看当前话语的 current-only 模型。

面板 (a)：测试期推理

左侧表示测试阶段。模型首先接收当前话语的文本、音频和视频，以及严格早于当前话语的同说话人历史。共享多模态编码器提取当前和历史表征，同时记录模态可靠度。随后，条件边际效用预测器结合当前查询、候选历史、已选集合、时间间隔和模态质量，预测该候选的边际效用分布以及发生负迁移的概率。选择器在预算 K 内逐步加入安全边际最高的历史，只有候选的下置信界大于零时才加入。如果所有候选都不安全， S^* 就是空集，模型直接回退到 current-only。测试期不使用当前或历史真实情感标签，也不使用未来信息或在线更新阈值。

面板 (b)：效用学习

中间左支路表示训练阶段。为了避免标签泄漏，训练集内部按 dialogue、episode 或 session 进行嵌套 cross-fitting。对每个查询随机采样 4 到 8 个历史组合 S ，并选择一个不属于 S 的候选历史 h_i 。折外预测器分别产生 f_0 、 f_S 和 f_{S+h_i} ，再利用加入候选前后的预测损失差构造条件边际效用标签 M 。该标签用于训练效用分布预测器。这里没有预先假定情感模型与效用模型必须通过一个联合损失端到端优化。

面板 (b)：策略校准

中间右支路表示独立校准。单条历史的置信区间不能自动保证自适应选择后的整个集合安全，因此需要在独立 calibration split 上冻结一组候选策略阈值，按聚类单位检验完整策略相对 current-only 的 excess risk，并选择满足风险约束的最激进策略。最终阈值在测试前冻结。需要注意，这种风险保证依赖独立性、交换性或聚类交换性假设，不能被表述为对任意时间漂移的绝对安全保证。

面板 (c)：实验验证

右侧给出实验协议。MELD 主要用于快速 Pilot 和自然负迁移审计，EmotionTalk 用于组合效用主实验，IEMOCAP 用于深历史、状态转折与恢复验证。基线既包括 current-only、full-history、Recent-k、Time Decay 和 Semantic RAG，也包括 point utility gate、SelectiveNet、MemCon、CARMA 消融和 Oracle 上界。评价除了 macro/weighted F1，还必须报告 harm rate、excess loss、尾部伤害、风险-覆盖率曲线、概率校准指标、历史交互的符号反转率以及状态恢复轨迹。

总结

因此，这张图的核心贡献可以概括为两点：第一，把历史使用从逐条独立评分升级为依赖已选集合的组合条件边际效用学习；第二，以 current-only 为安全基准，对完整历史选择策略进行独立校准，并在风险不可接受时选择性回退。合成实验只能验证算法逻辑，最终主张仍需真实数据上的自然负迁移、历史交互和跨数据稳定性证据。